UNIVERSITÉ DE LYON

Lyon 1

kubernetes

Vladimir Ostapenco
pro@vladost.com

Qui je suis?

- **Ingénieur DevOps - Freelance**
  - Plus de 8 ans d'expérience dans les technologies cloud
  - Spécialisé dans
    - Orchestration de conteneurs, automatisation et l'optimisation des déploiements et des processus, intégration des pratiques et de la culture DevOps au sein des équipes
- **Background**
  - Master SRIV - Université Lyon 1
  - Ingénieur infrastructure / DevOps
  - Entrepreneur et développeur open-source blockchain
  - Thèse sur les impacts environnementaux du cloud
- **Page perso et mail**
  - https://vladost.com
  - pro@vladost.com

Vladimir Ostapenco

Déploiement d'applications

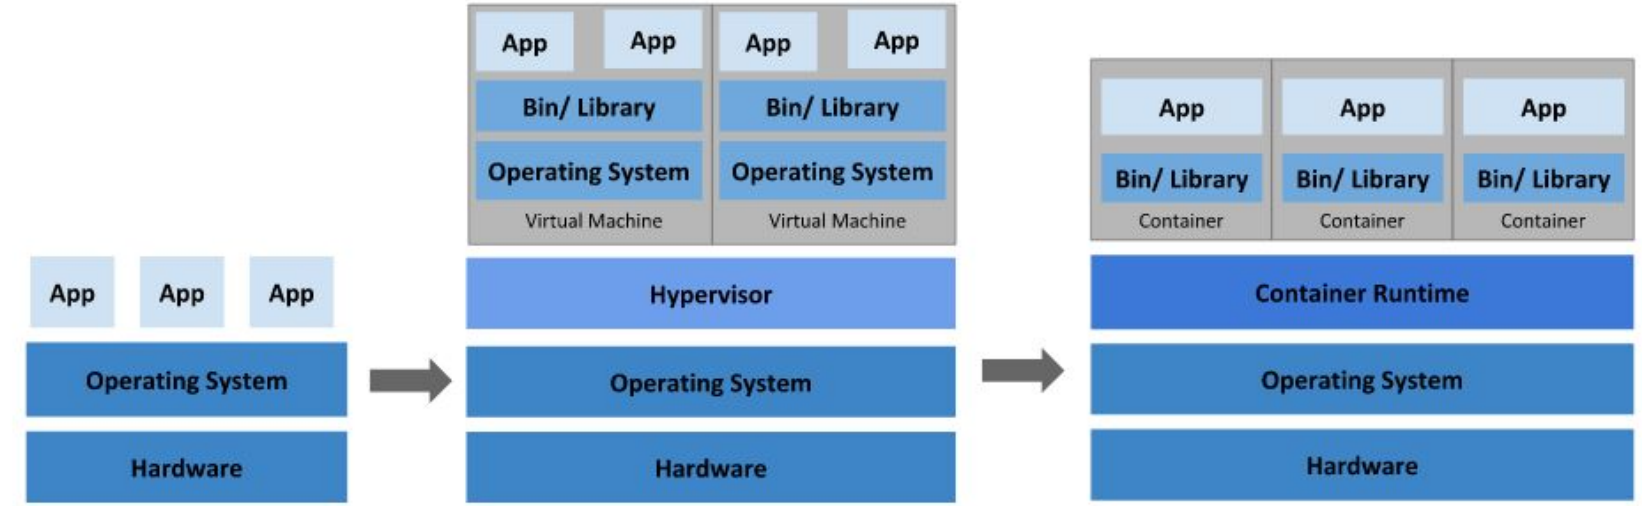

Source : kubernetes.io

Conteneurs vs VMs

- Conteneurs sont similaires aux VMs
- Ont des propriétés d'isolation assouplies, car partagent
  - Noyau du système d'exploitation
  - Certaines bibliothèques et binaires
- Sont légers
  - Taille de quelques mégaoctets
  - Démarrent en quelques secondes
- Ont leur propre système de fichiers avec
  - Bibliothèques et binaires
- 2 à 3 fois plus de conteneurs que de VMs sur le même serveur

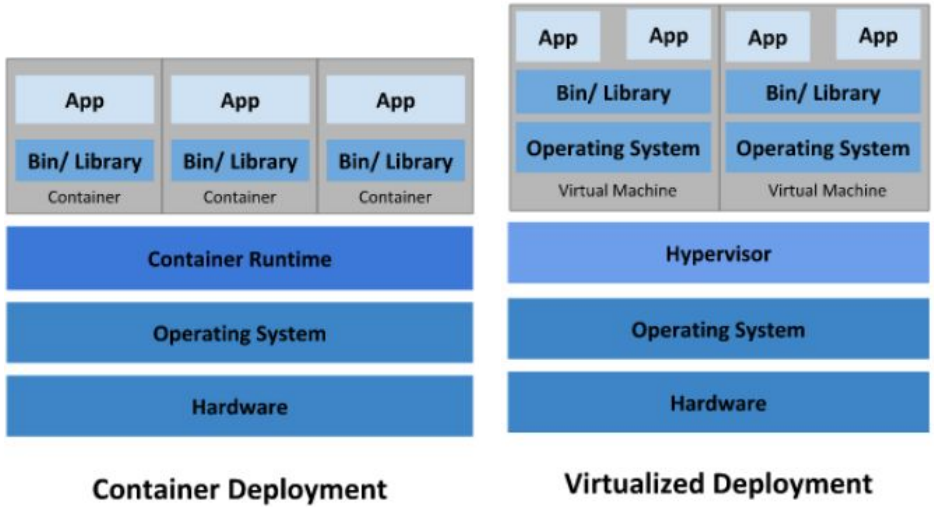

Source : kubernetes.io

Avantages de la conteneurisation

- **Très bon niveau de portabilité**
  - Fonctionne sur Ubuntu, RHEL, CoreOS…
  - On premise, sur les clouds publics et partout ailleurs
- **Cohérence de l'environnement**
  - Tout au long du cycle de développement, des tests et de la production
  - Fonctionne de la même manière sur un ordinateur portable que dans le cloud
- **Agilité dans le développement et déploiement**
  - Facilité et efficacité de la création d'images par rapport aux images VM
  - Facilité de déploiement des applications
- **Facilité d'utilisation dans le contexte d'intégration et déploiement continus**
  - Permet des déploiements fiables et fréquents
  - Avec des mécanismes de Rollbacks rapides et efficaces
- **Isolation des ressources**
- **Faible surcharge en ressources**

Microservices

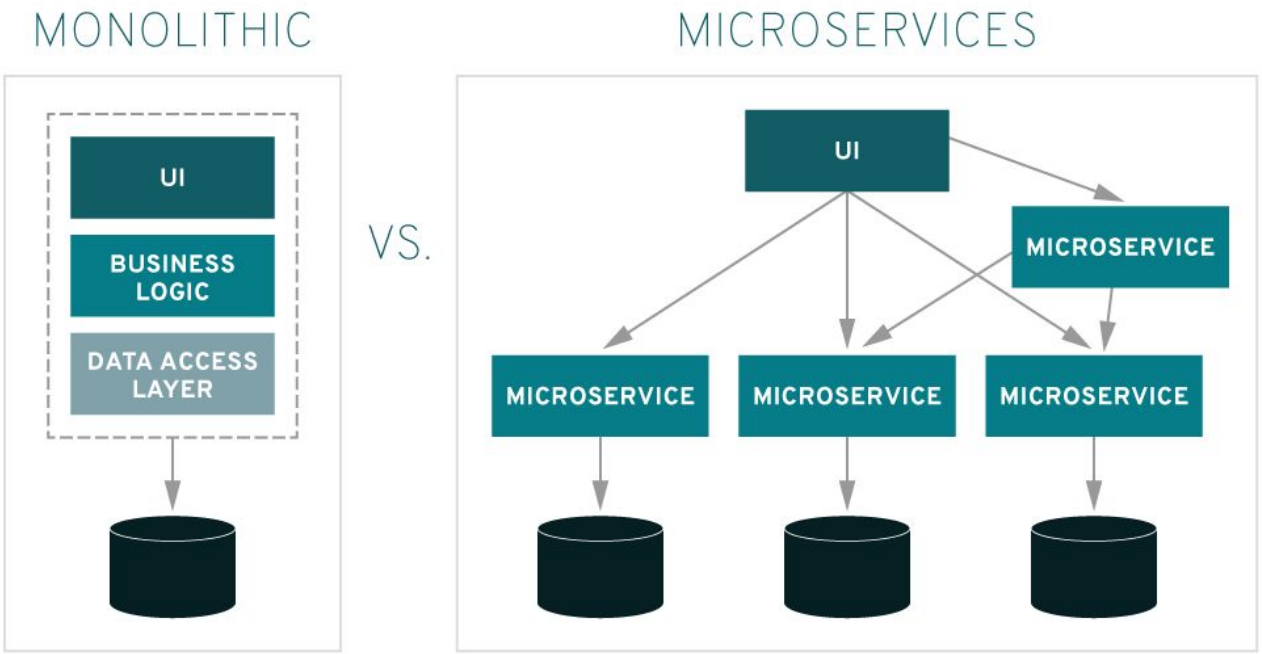

Source : redhat.com

Exemple d'architecture en microservices - Uber

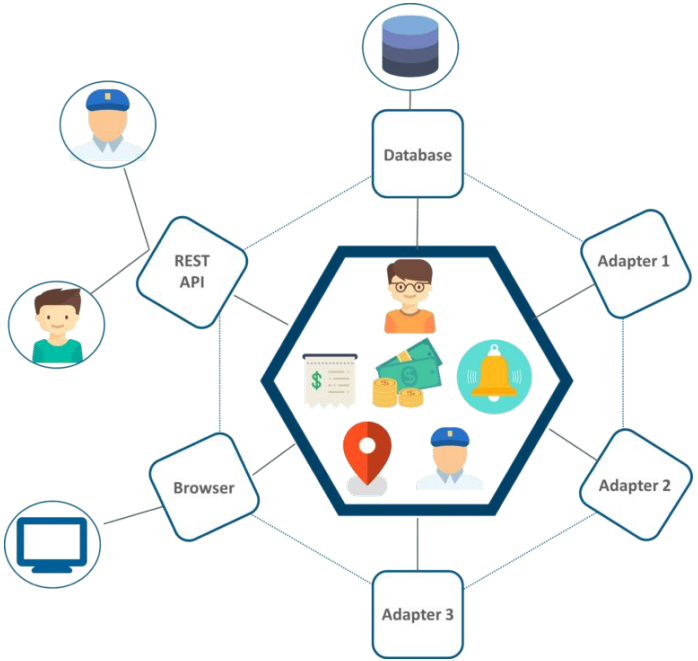

Architecture monolithique

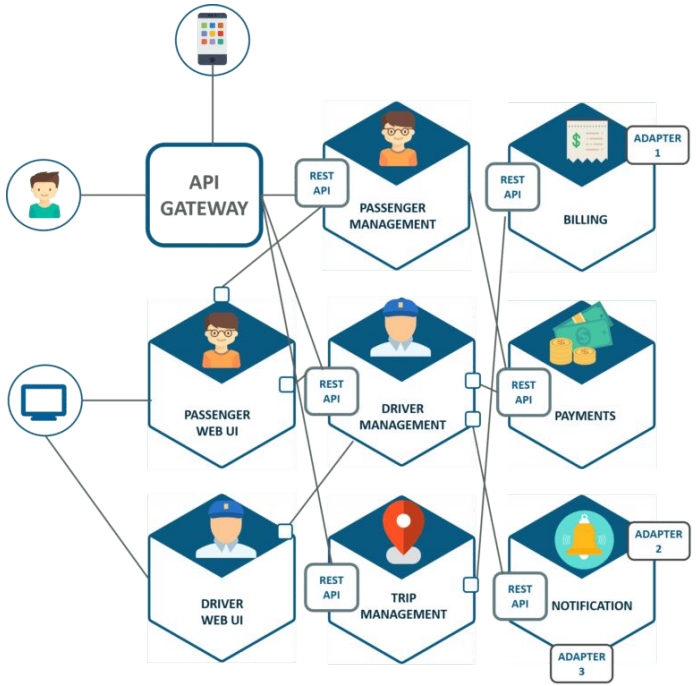

Architecture en microservices

Source : dzone.com

Avantages des microservices

- **Time-to-market plus rapide**
  - Cycles de développement plus courts
  - Déploiement et des mises à jour plus agiles
- **Évolutivité améliorée**
  - Lorsque la demande pour certains services augmente, il suffit d’en déployer plus
- **Résilience améliorée**
  - Microservices sont indépendants
  - Défaillance d’un élément ne provoque pas la panne de l’ensemble de l’application
- **Facile à déployer et à déboguer**
  - Microservices sont relativement petits
  - Plus facile à créer, tester, déployer, déboguer et réparer
- **Accessibilité améliorée**
  - Développeurs peuvent plus facilement les comprendre, les mettre à jour et les améliorer
- **Flexibilité dans l'utilisation des technologies**
  - Grâce à l'utilisation d'API, les développeurs ont la liberté de choisir le meilleur langage et la meilleure technologie pour la fonction nécessaire

Microservices - Use Cases

- **Airbnb**
  - Livraisons de code en production lentes, car multiples Reverts et Rollbacks
  - *Création et maintenance des applications plus simples*
- **Wallmart**
  - 6 millions des requêtes par minute, gestion quasi impossible avec une architecture monolithique
  - *Performances améliorées*
- **Amazon**
  - Modification de la structure des équipes à trois niveaux à de petites équipes efficaces et autonomes gérant une application tout au long de son cycle de vie
  - *Équipes autonomes et multifonctionnelles beaucoup plus efficaces*
- **Netflix**
  - Croissance de la base d'utilisateurs très rapide, besoin d'une grande flexibilité
  - *Évolutivité simple et mise à l'échelle dynamique*

Microservices sans orchestration = enfer

« Sans un framework d'orchestration quelconque, vous avez juste des services qui s'exécutent “quelque part” où vous les configurez pour s'exécuter manuellement - et si vous perdez un nœud ou quelque chose tombe en panne, il faut le réparer manuellement. Avec un framework d'orchestration, vous déclarez à quoi vous voulez que votre environnement ressemble, et le framework le fait ressembler à cela » ***Sean Suchter, co-fondateur et CTO de Pepperdata.***

- Adidas (plusieurs releases par jour, 4000 conteneurs, 200 nœuds)
- Google (des milliards des conteneurs par semaine)

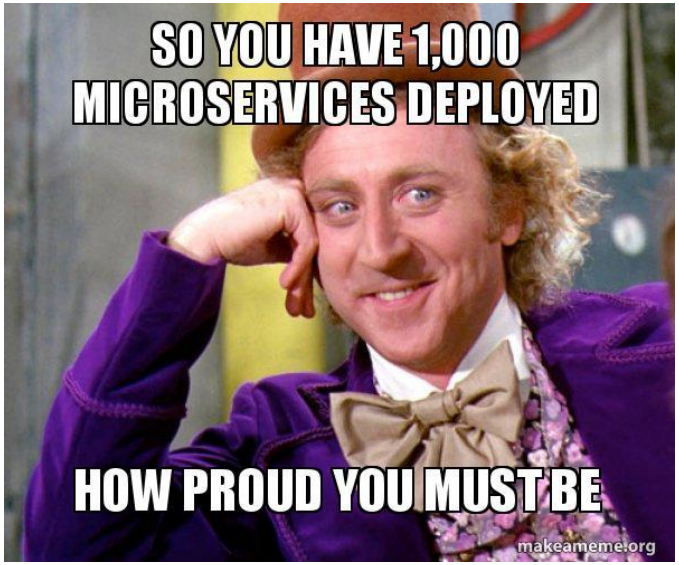

Kubernetes (K8s) vient à la rescousse !

Kubernetes (K8s) est une plateforme open source portable et extensible permettant de gérer les charges de travail et les services conteneurisés, permettant à la fois la configuration déclarative et l'automatisation

- S’appuie sur **15 années d’expérience** dans la gestion de charges de travail de production chez Google, associé aux meilleures idées et pratiques de la communauté

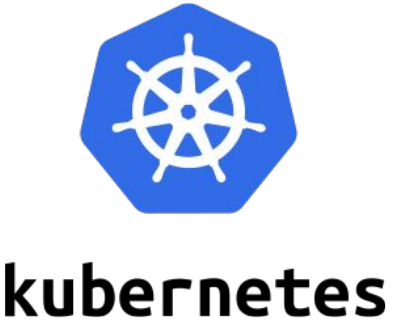

Source : kubernetes.io

Kubernetes (K8s)

- Conçu pour le déploiement
- Est flexible (Run anywhere)
- Est capable de gérer des millions des conteneurs
- Optimise l’utilisation des ressources
- Permet zero downtime
- Est DevOps friendly
- Est Open Source
    - Soutenu par une communauté active (~ 3900 contributeurs sur GitHub)

Kubernetes (K8s)

- **Kubernetes propose**
  - Découverte de service et équilibrage de charge
  - Orchestration du stockage
  - Déploiements automatisés avec un mécanisme de Rollback
  - Bin packing automatique
  - Self-healing
  - Gestion des secrets et des configurations
  - Exécutions en mode batch
  - Mise à l'échelle horizontale
  - Extensibilité

« Kubernetes is the new Linux OS of the Cloud »

Source : sumlogic.com

Kubernetes (K8s)

- Avantages pour le business
  - Délais de commercialisation plus rapides
  - Optimisation des coûts IT
  - Amélioration de l'évolutivité et de la disponibilité des services
  - Flexibilité multi cloud
  - Migration transparente vers le cloud

- Quelques stats (en 2024) [1]
  - 91 % des organisations utilisent des conteneurs en production
  - 80 % des organisations utilisent Kubernetes en production
    - Avec une croissance de 14 % par rapport à 2023
    - 13 % des organisations le testent ou l’évaluent activement

1 - https://www.cncf.io/reports/cncf-annual-survey-2024/

Kubernetes (K8s) : Sauve des entreprises !

Architecture

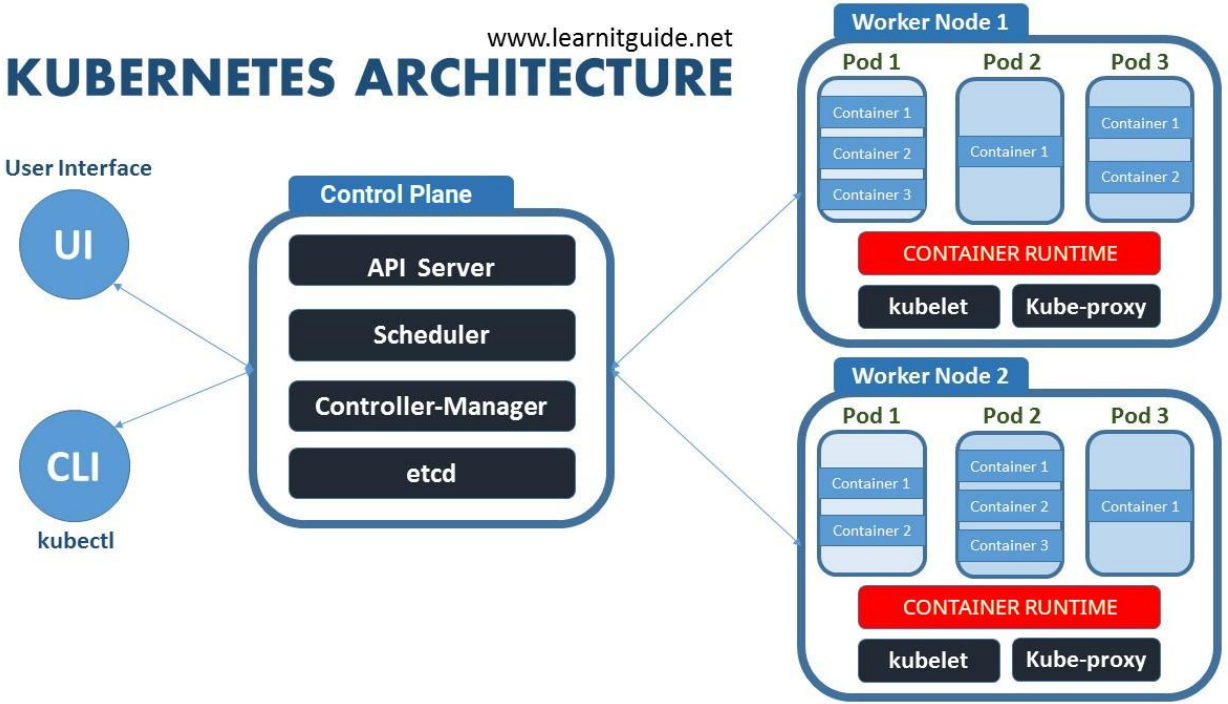

Architecture : Control Plane

- Composants du ***Control Plane*** prennent des décisions globales concernant le cluster, ainsi que détectent et répondent aux événements du cluster
- Composants du ***Control Plane***
  - **API Server** (kube-apiserver) — frontend pour le Control Plane
    - Expose Kubernetes API
    - Hub de communication pour les composants K8s
  - **Etcd** — base de données clé/valeur pour les données du cluster
  - **Scheduler** (kube-scheduler) — assigne votre application à un Worker Node
    - Détecte les exigences de l'application et la place sur un nœud qui répond à ces exigences
  - **Controller manager** (kube-controller-manager) — maintient le cluster en état opérationnel, gère les pannes de nœuds, réplique les composants, maintient le bon nombre d'instances d'applications…
- Par défaut, ne lance aucun conteneur et peut être répliqué pour améliorer la disponibilité
  - Options for Highly Available Topology

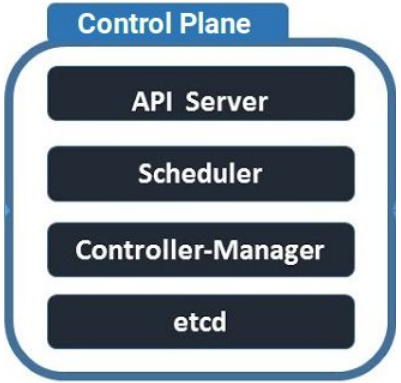

Architecture : Worker Node

- Maintient des conteneurs en état opérationnel et fournit l'environnement d'exécution Kubernetes
- Composants du ***Worker Node***
  - **kubelet** — gère les conteneurs sur le nœud et communique avec l'API Kubernetes
  - **kube-proxy** (service proxy) — gère les règles réseau sur les nœuds
    - Ces règles permettent la communication avec vos conteneurs
  - **Container Runtime** — exécute vos conteneurs (containerd, CRI-O, docker...)
    - Tout environnement d'exécution qui implémente Kubernetes ***CRI***
    - Plusieurs runtimes possibles au sein du même cluster

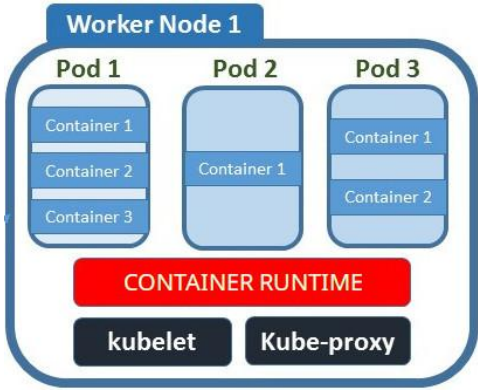

Kubernetes (K8s) : Abandon de Docker

- **Kubelet** utilise **CRI (Container Runtime Interface)** comme protocol pour communiquer avec **Container Runtime**
- Docker Engine API n’est pas compatible avec le CRI
  - **dockershim** a été utilisé comme un pont entre API docker et CRI
- Kubernetes n'utilise pas les fonctionnalités de networking et de volume livrées avec Docker par défaut
  - Ces fonctionnalités inutilisées peuvent entraîner des risques de sécurité
- **Dockershim** a été supprimé dans la version v1.24 (2022)
- Alternatives
  - **Containerd** (Fait partie et compatible avec Docker)
    - Container Runtime par défaut à partir de K8s v1.24
  - **CRI-O**
    - Approche plus minimaliste développée par RedHat et optimisé pour K8s
  - Installation et configuration de **cri-dockerd** avec Docker Engine

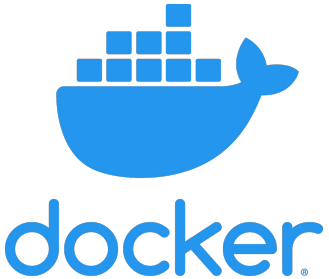

Moving Forward - Concepts Kubernetes

- API Server et Objets Kubernetes
- Namespaces
- Pods
- Workloads
- Labels, selectors et Annotations
- Services
- Scheduling
- Networking
- Stockage
- initContainers
- Variables d'environnement
- Secrets et ConfigMaps
- Surveillance des applications
- Cloud controller
- Déploiement d’un cluster Kubernetes

API Server

- Composant principal du Control Plane qui expose l'API Kubernetes
- Hub de communication
  - Permet aux différentes parties de votre cluster de communiquer entre eux
- Chaque composant Kubernetes communique exclusivement via l'API server
  - Composants ne communiquent pas directement
- Seul composant qui communique directement avec le **etcd**
- Permet d'interroger, manipuler et valider les objets K8s (services, volumes, etc)
- **Kubectl —** l'outil CLI qui permet d'utiliser l'API server pour gérer les objets K8s
  - **kubectl get nodes** — afficher l'état des nœuds du cluster
- API server peut aussi être utilisé
  - À partir de vos applications via une lib C, Go, Python, Java, Rust...
  - Directement via les appels à l'API REST

Objets Kubernetes

- Tout sur la plateforme K8s est traité comme des objets K8s
  - Services, volumes, secrets, noeuds...
- Unités persistantes représentant l'état de votre cluster
  - Stockés dans **etcd**
- Sont généralement définis au format **YAML**
  - Langage de sérialisation de données simple et lisible
- Une fois créés, K8s s'assure qu'ils existent et sont fonctionnels
- Doivent contenir les champs suivants
  - apiVersion - version de l'API Kubernetes utilisé pour créer l'objet (v1alpha1, v3beta2, v1)
  - kind - type de l'objet
  - metadata - données qui aident à identifier l'objet (nom, label, UID, namespace...)
  - spec - description de l'état souhaité pour l'objet

nginx.yaml

```
apiVersion: v1
kind: Pod
metadata:
  name: nginx
  labels:
    service: web
spec:
  containers:
  - name: nginx
    image: nginx:1.14.2
    ports:
    - containerPort: 80
```

Namespaces

- Permet d'isoler des groupes de ressources au sein d'un seul cluster
- Moyen de diviser les ressources du cluster entre plusieurs utilisateurs
  - Séparation du cluster entre différentes équipes, projets ou environnements
  - Permet de définir des limites d'utilisation des ressources (*ResourceQuota*)
- Namespaces initiés à la création du cluster
  - **default** — namespace par défaut pour les objets sans autre namespace
  - **kube-system** — namespace pour les objets nécessaires au cycle de vie d'un cluster K8s
  - **kube-public** — namespace créé automatiquement et lisible par tous les utilisateurs
    - Utilisé par le cluster, au cas où certaines ressources devraient être visibles et lisibles publiquement
  - **kube-node-lease** — namespace dédié aux objets responsables des heartbeats des nœuds afin de détecter les pannes de nœuds
- **NB :** Noms des ressources doivent être uniques dans un namespace

Pod

- Unité de base de Kubernetes
  - Plus petite unité que vous pouvez déployer dans K8s
- Représente une unité de déploiement
  - Instance unique d'une application
  - Regroupe **un** ou **plusieurs conteneurs étroitement couplés** qui partagent des ressources (colocalisés et coplanifiés)
- Encapsule
  - Un ou plusieurs conteneurs
  - Ressources de stockage
  - Ressources réseau
    - Possède une adresse IP unique à l'échelle du cluster
  - Options d’exécution des conteneurs
- Normalement, vous ne manipulez pas les Pods directement
  - Conçus comme des entités relativement éphémères et jetables

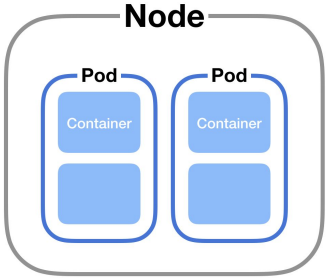

nginx.yaml

```
apiVersion: v1
kind: Pod
metadata:
  name: nginx
spec:
  containers:
  - name: nginx
    image: nginx:1.14.2
    ports:
    - containerPort: 80
```

Workload objects

- **Workload objects** - niveau d'abstraction plus élevé qu'un Pod
- Permettent une gestion déclarative des applications
- En fonction de la spécification de workload object, le Control Plane crée et gère automatiquement les Pods
- Workload objects par défaut
  - **Deployment** et **ReplicaSet**
  - **StatefulSet**
  - **DaemonSet**
  - **Job** et **Cronjob**

Workloads: Deployment

- Manière la plus courante pour déployer une application sur un cluster K8s
- Dans un Deployment
  - Vous décrivez l'état souhaité pour votre application
  - K8s change l'état actuel en l'état souhaité à un rythme contrôlé
- Propose des mécanismes
  - Mises à jour déclaratives avec les mécanismes de Rollling update et de Rollback
  - Mise à échelle (Scale up) pour supporter plus de charge
- Quelques commandes
  - **kubectl apply -f deployment.yaml** — créer un déploiement
  - **kubectl get deployments** — afficher les déploiements
  - **kubectl describe deployments** — afficher la description complète d'un déploiement

nginx-deployment.yaml

```
apiVersion: apps/v1
kind: Deployment
metadata:
  name: nginx-deployment
  labels:
    app: nginx
spec:
  replicas: 3
  selector:
    matchLabels:
      app: nginx
  template:
    metadata:
      labels:
        app: nginx
    spec:
      containers:
      - name: nginx
        image: nginx:1.7.9
        ports:
        - containerPort: 80
```

Workloads: Deployment

- Ressource de haut niveau englobant un **ReplicaSet**
  - Un ou plusieurs Pods répliqués
  - Garantit qu'un certain nombre des Pods est un cours d'exécution à tout moment
  - Doit toujours être créé par un Deployment
- Dans un Deployment **les Pods sont éphémères**
  - Peuvent être remplacés, recréés ou redémarrés à tout moment
  - Ensemble de Pods d'un Deployment exécuté sur le cluster à l'instant T n'est pas forcément celui qui sera exécuté à l'instant T+1
  - Seul leur nombre est garanti
  - Bon choix **pour** gérer **les applications sans état**

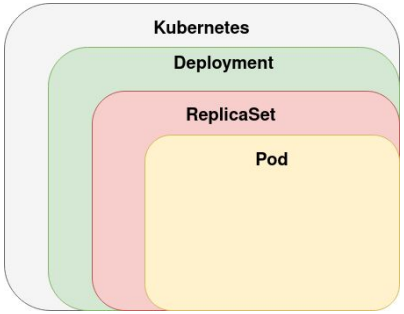

Workloads: StatefulSet

- Workload object adapté à la gestion des applications avec état (Stateful) qui
  - Fournit des garanties relatives à l'ordre et à l'unicité de ces Pods
  - Contrairement à un Deployment, conserve une identité permanente pour chacun de ses Pods
- Pods créés ne sont pas interchangeables
- Si un Pod est défaillant, il est remplacé par un autre avec le même nom d'hôte et les mêmes configurations
- Utile pour les applications qui nécessitent un ou plusieurs des éléments suivants
  - Identifiants réseau stables et uniques
  - Stockage persistant
  - Déploiement, mise à l'échelle et mises à jour ordonnés
- Quelques commandes
  - **`kubectl get statefulsets`**
  - **`kubectl describe statefulsets`**

Workloads: DaemonSet

- Workload object qui
  - Garantit que tous (ou certains) nœuds exécutent une copie du Pod
  - N’utilise pas l'ordonnanceur par défaut
- Lorsque des nœuds sont ajoutés au cluster, des Pods d’un DaemonSet y sont ajoutés automatiquement
- Exemples d'utilisation
  - Solutions de supervision ou de gestion des logs
  - Composants proxy et réseau de Kubernetes (**kube-proxy**)
- Quelques commandes
  - **`kubectl get daemonset`**
  - **`kubectl describe daemonset`**

Workloads: Job et Cronjob

- **Job** peut être vu comme une tâche
  - Crée un ou plusieurs Pods qui exécutent une tâche et s'arrêtent
  - Pods ne sont pas supprimés automatiquement après leur arrêt
  - Permet d'exécuter plusieurs Pods en parallèle
- **Cronjob** permet de planifier l'exécution des Jobs
- Exemples d'utilisation
  - **Job**: Conversion d’une vidéo
  - **Cronjob**: Backup d’une base des données

blender-job.yaml

```
apiVersion: batch/v1
kind: Job
metadata:
  name: blender
spec:
  template:
    spec:
      containers:
      - name: blender
        image: blender-render
        command: ["render", “./movie.zip”]
      restartPolicy: Never
  backoffLimit: 4
```

Labels et Label selectors

- **Labels**
  - Paires clé / valeur attachées à des objets K8s (tels que Pods)
  - Utilisés pour identifier des objets et organiser des sous-ensembles d'objets
  - Exemple
    - `"app" : "nginx", "environment" : "production"`
  - Peuvent être attachés aux objets au moment de la création ou ajoutés et modifiés à tout moment
  - Chaque clé doit être unique pour un objet donné
- **Label selectors**
  - Permettent d’identifier et de sélectionner un ensemble d'objets

nginx-deployment.yaml

```
apiVersion: apps/v1
kind: Deployment
metadata:
  labels:
    app: nginx
  name: nginx-deployment
spec:
  replicas: 3
  selector:
    matchLabels:
      app: nginx
  template:
    metadata:
      labels:
        app: nginx
    spec:
      containers:
      - name: nginx
        image: nginx:1.7.9
        ports:
        - containerPort: 80
```

Annotations

- Permettent d’attacher des métadonnées à vos objets
- Ne peuvent pas être utilisés pour identifier ou sélectionner des objets
- Peuvent être utilisés par des outils et des bibliothèques
- Exemples
  - Information sur la version de l’application ou de l’image docker
  - Repository avec le code source de l’application
  - Coordonnées des personnes responsables

annotations-pod.yaml

```
apiVersion: v1
kind: Pod
metadata:
   annotations:
    imageregistry: "https://hub.com/"
   name: annotations
spec:
  containers:
  - name: nginx
    image: nginx:1.14.2
    ports:
    - containerPort: 80
```

Accès aux Pods

- Chaque Pod obtient **sa propre adresse IP**
- Dans un déploiement
  - Ensemble de Pods s'exécutant à un moment donné, peut-être différent de l'ensemble de Pods exécutant un instant plus tard
- Problème
  - Dans une configuration frontend/backend
  - Comment les Pods du Frontend trouvent-ils et gardent-ils la trace de l'adresse IP à laquelle se connecter afin d'utiliser le backend ?

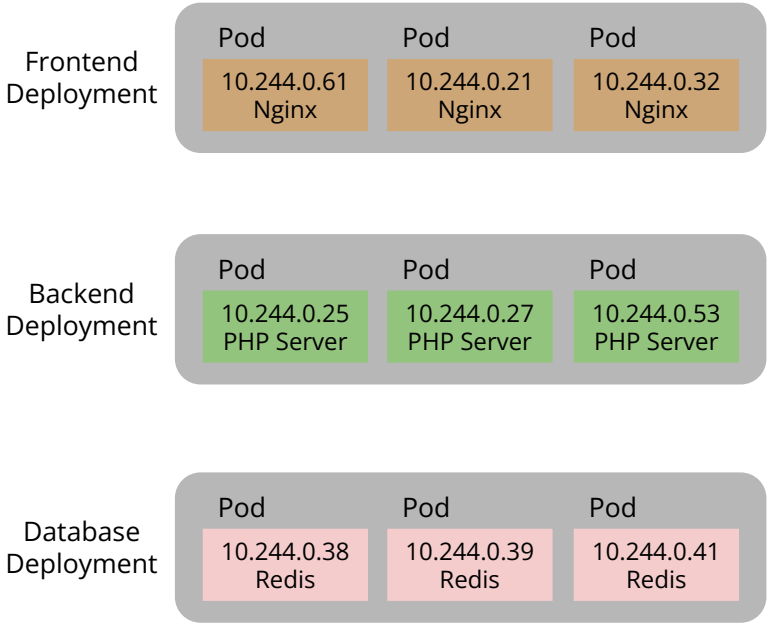

Services

- Permet d'exposer vos Pods en tant que service réseau et d'effectuer une résolution d'applications entre les Pods
- Est une abstraction qui définit un ensemble logique de Pods et une politique permettant d'y accéder
  - Parfois appelée microservice
  - A une adresse IP définie
  - Décide de router le trafic vers l'un des Pods (load balancing)
- Ensemble de Pods ciblés par un service est déterminé par un ***Label Selector***

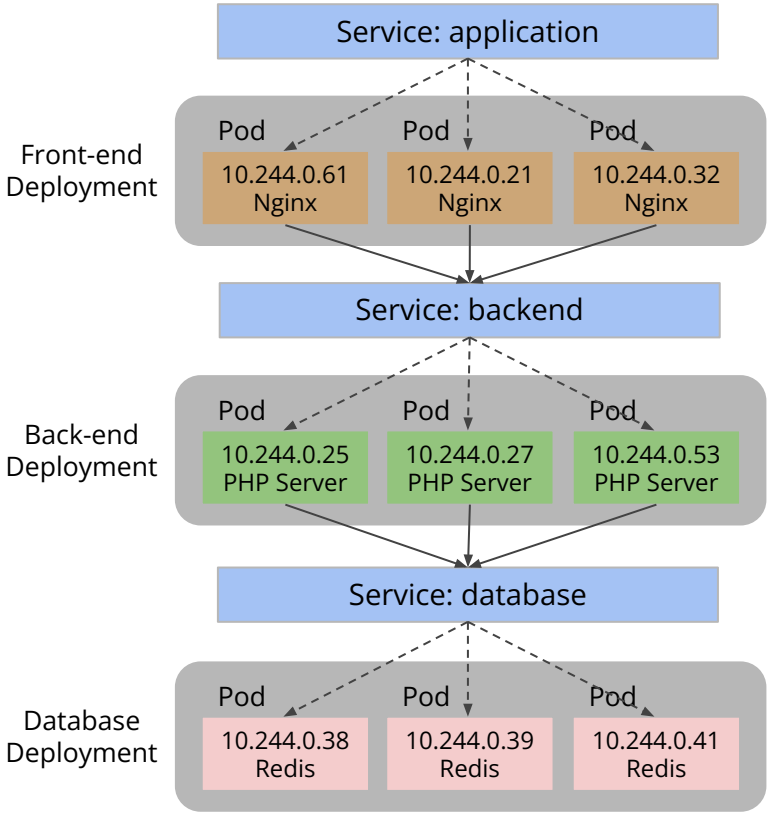

Services : Types

- **ClusterIP** (par défaut) — Expose le service sur une adresse IP interne au cluster (Idéal pour backend)
- **NodePort** — Expose le service sur un port statique sur chaque nœud du cluster
- **LoadBalancer** — Exposer le service à l'aide d'un load balancer externe (fournisseur de cloud)
- **ExternalName** — Mappe le service à un nom DNS externe (champ *externalName*)
  - Requête DNS sur le nom de service renvoie CNAME avec la valeur du champ *externalName*
  - Utile lors de la migration progressive de vos services sur K8s

nginx-service.yaml

```yaml
apiVersion: v1
kind: Service
metadata:
  name: nginx-service
spec:
  selector:
    app: nginx
  ports:
  - name: http
    protocol: TCP
    port: 80
    targetPort: 80
```

nginx-deployment.yaml

```yaml
apiVersion: apps/v1
kind: Deployment
metadata:
  name: nginx-deployment
  labels:
    app: nginx
spec:
  replicas: 3
  selector:
    matchLabels:
      app: nginx
  template:
    metadata:
      labels:
        app: nginx
    spec:
      containers:
      - name: nginx
        image: nginx:1.7.9
        ports:
        - containerPort: 80
```

Services : Découverte

Principales méthodes de découverte d'un Service dans le cluster

- **Variables d'environnement**
  - **Kubelet** ajoute dans chaque Pod un ensemble de variables d'environnement pour chaque service actif
  - Pour le service *svcname*
    - Les variables *{SVCNAME}_SERVICE_HOST* et *{SVCNAME}_SERVICE_PORT* seront disponibles dans chaque Pod
- **DNS**
  - Un service DNS doit être configuré sur le cluster
  - Le service DNS surveille les nouveaux services et crée des enregistrements DNS
  - Pour le service *my-service* dans le namespace *my-ns* une entrée DNS *my-service.my-ns* sera créé
    - Pods dans le namespace *my-ns* peuvent trouver le service en utilisant le nom DNS *my-service* ou *my-service.my-ns*
    - Pods de l'autre namespace doivent utiliser *my-service.my-ns*

Ingress

- Gère l'accès externe HTTP ou HTTPS aux services
- Peut fournir
  - URLs accessibles de l'extérieur pour les services
  - Équilibrage de charge
  - Terminaison SSL / TLS
  - Hébergement virtuel basé sur le nom de domaine
- Nécessite un **Ingress Controller**
- Types
  - **Single service** — permet d'exposer un seul service
  - **Simple fanout** — achemine le trafic vers plusieurs services, en fonction de l'URI HTTP demandé
  - **Name based virtual hosting** — achemine le trafic vers plusieurs services, en fonction du hostname demandé

simple-fanout-ingress.yaml

```
apiVersion: networking.k8s.io/v1
kind: Ingress
metadata:
  name: simple-fanout
spec:
  rules:
  - host: foo.bar.com
    http:
       paths:
       - path: /foo
         pathType: Prefix
         backend:
           service:
              name: service1
              port:
                number: 4200
       - path: /bar
         pathType: Prefix
         backend:
           service:
              name: service2
              port:
                number: 8080
```

Exemple de déploiement

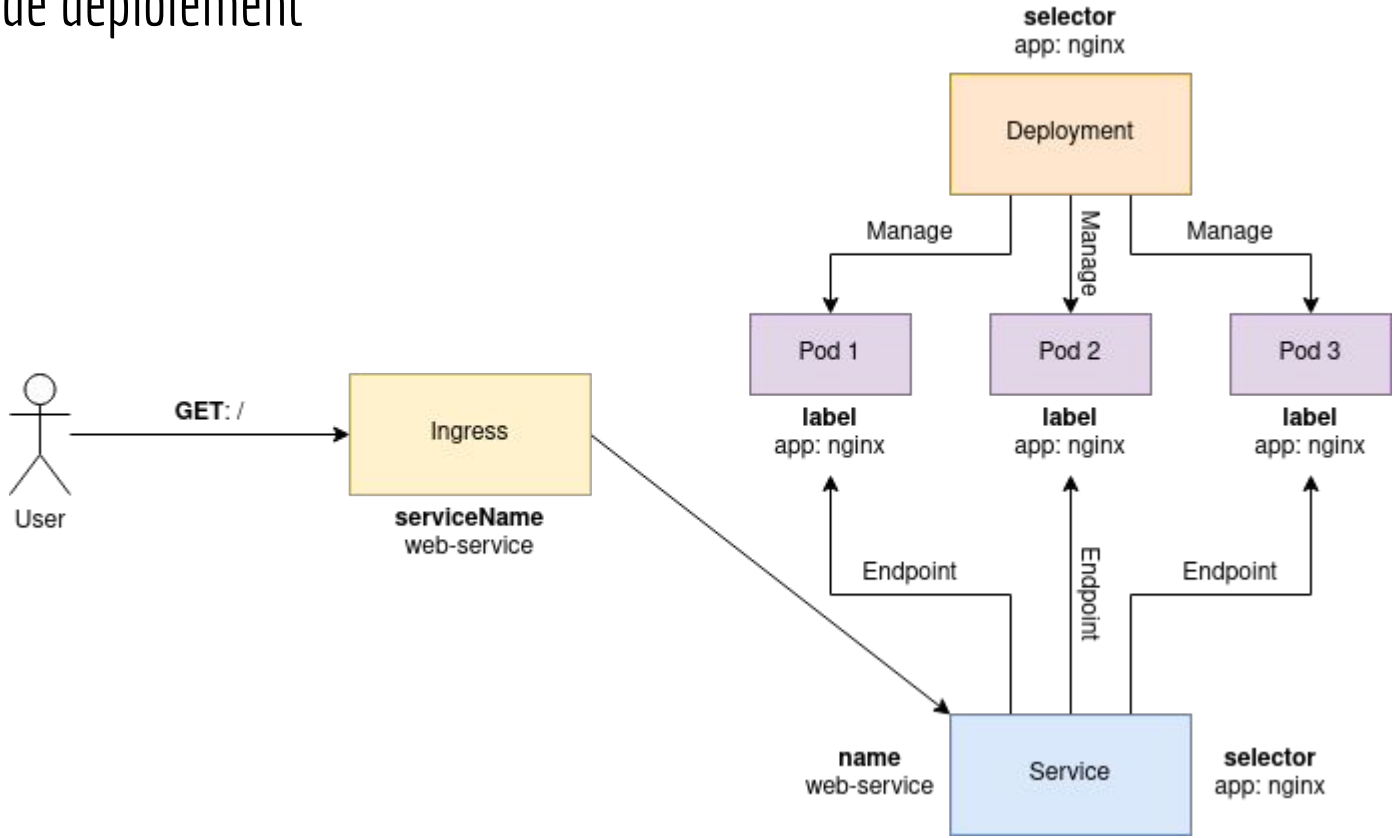

Scheduling

- Scheduler surveille les Pods nouvellement créés qui n'ont pas été attribués à un nœud
  - Pour chaque Pod découvert, trouve le meilleur nœud pour ce Pod
- *kube-scheduler* sélectionne un nœud pour un Pod en deux étapes
  - **Filtering** — trouve l'ensemble de nœuds où il est possible de planifier le Pod
    - Par exemple, si le nœud dispose de suffisamment de ressources disponibles pour répondre aux ***demandes de ressources spécifiques d'un pod***
  - **Scoring** — classe les nœuds restants pour choisir le placement de Pod le plus approprié
    - Attribue un score à chaque nœud qui a survécu au filtrage, en basant ce score sur les règles de notation
      - En tenant compte de l'utilisation des ressources, de la capacité des nœuds et des exigences de communication entre les Pods...
  - **kube-scheduler** attribue le Pod au Node avec le classement le plus élevé (aléatoire si plusieurs nœuds ont le même score)
- Vous pouvez créer votre propre scheduler!

Scheduling: Requests et Limits

- Permet de spécifier la quantité des ressources dont un conteneur a besoin
- **Requests**
  - “Soft cap”
  - Utilisé seulement pendant le scheduling
- **Limits**
  - “Hard cap”
  - Container Runtime empêche le conteneur d'utiliser plus
- **Types de ressources**
  - **CPU** exprimé en CPU units : 1 CPU unit = 1 CPU ou vCPU = 1000m
  - **Mémoire** exprimé en nombre des octets
    - Peut être suivi d'un suffixe comme M, K ou Mi, Ki etc.

frontend-pod.yaml

```
apiVersion: v1
kind: Pod
metadata:
  name: frontend
spec:
  containers:
  - name: app
    image: app:v4
    resources:
      requests:
        memory: "64M"
        cpu: "250m"
      limits:
        memory: "128M"
        cpu: "500m"
```

Networking : Communication

- Tous les Pods peuvent communiquer avec tous les autres Pods, qu'ils se trouvent sur le même nœud ou sur des nœuds différents
- **Au sein du même nœud**
  - Un Pod voit un périphérique Ethernet normal ***eth0***
  - Un tunnel qui connecte le réseau du Pod avec le réseau du nœud est créé
    - Ce tunnel contient deux interfaces virtuelles
      - Dans le conteneur (***eth0***)
      - Sur le nœud (***vethX***)
  - **Linux Ethernet Bridge** permet la communication entre les Pods
    - Contient toutes les interfaces ***vethX*** de tous les Pods exécutés sur le nœud
- **Entre les nœuds**
  - Container Network Interface (CNI)

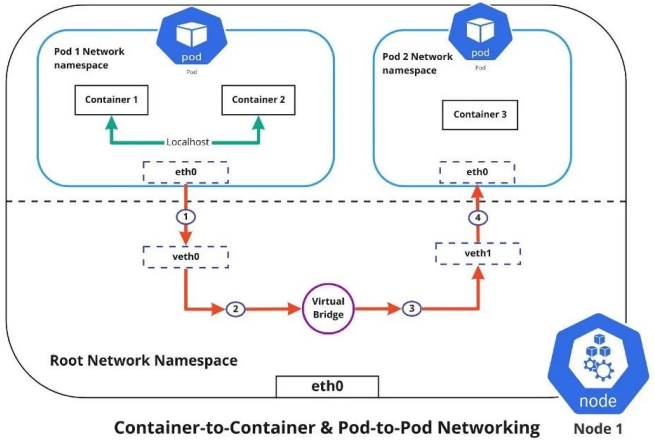

Container-to-Container & Pod-to-Pod Networking Node 1

(Nived Velayudhan, CC BY-SA 4.0)

Networking: Container Network Interface (CNI)

- Utilisé pour la communication entre les nœuds
- Garantit que tous les Pods peuvent communiquer avec tous les autres Pods exécutés sur n'importe quel autre nœud sans NAT
- Installé via un plugin et n'est pas natif à la solution K8s
  - Installe et lance un agent de réseau sur chaque nœud (***DaemonSet***)
- CNI les plus connus
  - ***Flannel*** — configure un réseau overlay IPv4 de niveau 3 basé souvent sur VXLAN
  - ***Calico*** — configure un réseau niveau 3 basé sur BGP, pas d'encapsulation
  - **Cilium** — basé sur eBPF (très performant), il prend en charge le chiffrement, l'authentification, les politiques de sécurité avancées et l'observabilité

Stockage

- Stockage dans un conteneur est éphémère
- Cela pose deux problèmes
  - **Perte de fichiers** lorsqu'un conteneur plante
    - État du conteneur n'est pas enregistré, donc tous les fichiers créés ou modifiés sont perdus
    - **kubelet** redémarre le conteneur, mais avec un état propre
  - **Partage des fichiers** entre des conteneurs exécutés au sein du même Pod
- Nécessité d'un stockage persistant
  - Volumes Kubernetes

Stockage : Volumes

- Volumes Kubernetes peuvent être
  - **Éphémères** — ont une durée de vie d'un Pod
  - **Persistantes** — existent au-delà de la durée de vie d'un Pod
- Types des volumes
  - **emptyDir** — volume initialement vide, créé pour lorsqu'un Pod est attribué à un nœud et existe tant que ce Pod s'exécute sur ce nœud
  - **hostPath** — monte un fichier ou un répertoire du système de fichiers du nœud dans un Pod
  - **configMap, secret** — un moyen d'injecter des données de configuration ou des secrets dans des Pods
  - **Cephfs, fc, nfs, iscsi** — permet à un volume existant d'être monté dans un Pod
  - **persistentVolumeClaim** — utilisé pour monter un volume persistant dans un Pod

pod-with-volume.yaml

```
apiVersion: v1
kind: Pod
metadata:
  name: pod-with-volume
spec:
  containers:
  - image: busybox
      name: test-container
      volumeMounts:
      - mountPath: /cache
        name: cache-volume
  volumes:
  - name: cache-volume
    emptyDir: {}
```

Stockage : Persistent Volumes

- Sous-système qui sépare la partie fourniture de stockage de la partie consommation de stockage
- Abstraction permettant de découpler
  - Volumes mis à disposition par les administrateurs
  - Demandes d'espace de stockage des développeurs pour leurs applications
- Composé de deux éléments (objets Kubernetes)
  - **PersistentVolume** — configuré par un administrateur ou provisionné dynamiquement par un *StorageClass*
  - **PersistentVolumeClaim** — peut être vu comme une demande de stockage et peut être attaché à un Pod

Stockage : Persistent Volume (PV)

- Configuré par un administrateur (statique) ou provisionné dynamiquement par un *Storage Class* (dynamique)
- A un cycle de vie indépendant de tout Pod individuel qui l'utilise
- Capture les détails de l'implémentation du stockage
  - qu'il s'agisse, de NFS, d'iSCSI, de FC ou d'un système de stockage spécifique au fournisseur cloud
- Types des PVs (implémentés sous forme de plugins)
  - **CSI**, FC, iSCSI, NFS, local et hostPath
- **kubectl get pv**

pv-volume.yaml

```
apiVersion: v1
kind: PersistentVolume
metadata:
  name: pv-volume
spec:
  storageClassName: manual
  capacity:
    storage: 200Mi
  accessModes:
    - ReadWriteOnce
  hostPath:
    path: "/mnt/data"
```

Stockage : Persistent Volume Claims (PVC)

- Permettent aux développeurs de demander du stockage pour leur applications sans avoir besoin de savoir où se trouve le stockage sous-jacent
- Utilisent (consomment) des Persistent Volumes
- Sont utilisés par les Pods
- Restent liées au Persistent Volume même si le Pod qui les utilisait a été supprimé
- Persistent Volume ne sera pas libéré tant que PVC lié existe
- **kubectl get pvc**

pv-claim.yaml

```
apiVersion: v1
kind: PersistentVolumeClaim
metadata:
  name: pv-claim
spec:
  storageClassName: manual
  accessModes:
    - ReadWriteOnce
  resources:
    requests:
      storage: 200Mi
```

pod.yaml

```
…
volumes:
  - name: mongodb-data
      persistentVolumeClaim:
        claimName: pv-claim
```

Stockage : Modes d’accès

- Permet de spécifier le mode d'accès pris en charge par un Persistant Volume
- Modes d'accès
  - **ReadWriteOnce** — seul un nœud peut monter le volume en lecture-écriture
  - **ReadOnlyMany** — plusieurs nœuds peuvent monter le volume en lecture
  - **ReadWriteMany** — plusieurs nœuds peuvent monter le volume en lecture-écriture
  - **ReadWriteOncePod** — le volume peut être monté en lecture-écriture par un seul Pod
- N'assurent pas la protection en écriture une fois le stockage monté
  - Utilisés pour associer les *PersistentVolumeClaims* aux *PersistentVolumes*
- PV ne peut être monté qu’en utilisant un mode d’accès à la fois, même s'il prend en charge plusieurs

Stockage : Politiques de rétention

- Indique au cluster que faire avec le Persistant Volume après qu'il a été libéré de sa claim
- **persistentVolumeReclaimPolicy**
  - **Retain** — gestion manuelle. Vous ne perdez aucune donnée lors de la suppression de claim
  - **Recycle** — le contenu sera supprimé pour être utilisé pour les nouveaux claims (*rm -rf /thevolume/**)
  - **Delete** — le stockage sous-jacent sera supprimé (GCP volume, Openstack Cinder volume)

pv-recycle.yaml

```
apiVersion: v1
kind: PersistentVolume
metadata:
  name: pv-recycle
spec:
  storageClassName: manual
  persistentVolumeReclaimPolicy: Recycle
  capacity:
    storage: 200Mi
  accessModes:
    - ReadWriteOnce
  hostPath:
    path: "/mnt/data"
```

Stockage : StorageClass

- Permet aux administrateurs de décrire les classes de stockage qu'ils proposent
- Permet le provisionnement automatique du stockage, sans qu'il soit nécessaire de créer un *PersistentVolume*
- Il suffit d'indiquer simplement au K8s de quel stockage vous avez besoin avec un *PersistentVolumeClaim* et il créera le *PersistentVolume* pour vous
- ***Provisioning dynamique***

sc-csi-cinder.yaml

```
apiVersion: storage.k8s.io/v1
kind: StorageClass
metadata:
  name: csi-cinder
provisioner: cinder.csi.openstack.org
parameters:
  availability: nova
```

mongodb-pvc.yaml

```
apiVersion: v1
kind: PersistentVolumeClaim
metadata:
  name: mongodb-pvc
spec:
  storageClassName: csi-cinder
  resources:
      requests:
      storage: 100Mi
  accessModes:
      - ReadWriteOnce
```

Stockage: Persistent Volumes

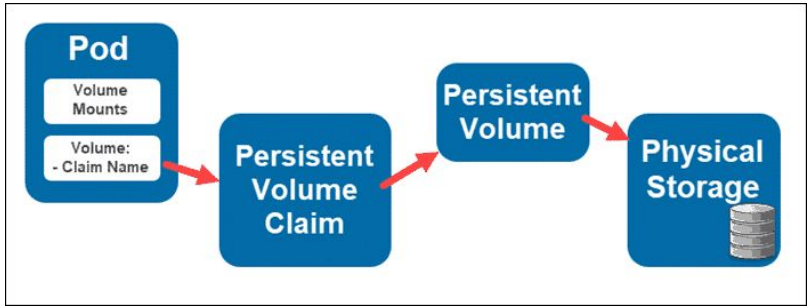

Source: phoenixnap.com

app-pod.yaml

```
apiVersion: v1
kind: Pod
metadata:
  name: app-pod
spec:
  containers:
  - image: busybox
       name: test-container
       volumeMounts:
       - mountPath: /app/data
         name: app-volume
  volumes:
  - name: app-volume
    persistentVolumeClaim:
      claimName: app-pvc
```

app-pvc.yaml

```
kind: PersistentVolumeClaim
apiVersion: v1
metadata:
  name: app-pvc
spec:
  storageClassName: manual
  accessModes:
       - ReadWriteMany
  resources:
       requests:
           storage: 100Mi
```

app-pv.yaml

```
kind: PersistentVolume
apiVersion: v1
metadata:
  name: app-pv
spec:
  storageClassName: manual
  capacity:
       storage: 100Mi
  accessModes:
       - ReadWriteMany
  hostPath:
       path: "/mnt/app"
```

Conteneurs d’initialisation (initContainers)

- Conteneurs spécialisés qui s'exécutent avant les conteneurs de l'application dans un Pod
- Peuvent être utilisés pour
  - Télécharger du code
  - Effectuer une configuration
  - Initialiser une base de données
- Un Pod peut avoir un ou plusieurs conteneurs d'initialisation
- Doivent se terminer avec succès avant le démarrage du conteneur principal

pod-with-init.yaml

```
apiVersion: v1
kind: Pod
metadata:
  name: pod-with-init
spec:
  volumes:
  - name: www
    emptyDir: {}
  containers:
  - name: nginx
    image: nginx
    volumeMounts:
    - mountPath: /www
      name: www
  initContainers:
  - name: init-nginx
    image: busybox
    command: ["init", "/www"]
    volumeMounts:
    - mountPath: /www
      name: www
```

Variables d’environnement

- Moyen le plus simple d’injecter des données dans vos applications
- Sont définis dans la description du Pod au niveau du conteneur
  - Avec le champ *env* ou *envFrom*
- Peuvent contenir des secrets (*Secrets*) et des configurations (*ConfigMaps*)
- Peuvent être interdépendants
  - Vous pouvez utiliser *$(VAR_NAME)* dans le champ *value* d’une autre variable d'environnement

pod-with-env-vars.yaml

```
apiVersion: v1
kind: Pod
metadata:
  name: pod-with-env-vars
spec:
  containers:
  - name: env-print-demo
      image: busybox
      env:
      - name: GREET
        value: "Greetings! $(NAME)"
      - name: NAME
        value: "Kubernetes"
      command: ["echo"]
      args: ["$(GREET)"]
```

Secrets

- Sont utilisés pour fournir les données sensibles aux Pods de manière sécurisée
- Sont créés indépendamment des Pods qui les utilisent
- Peuvent être fournis aux Pods sous forme de ***variables d'environnement*** ou de ***volumes***
- Utilisation sous forme des variables d'environnement est une mauvaise pratique
  - Certaines applications peuvent écrire toutes les valeurs des variables d'environnement dans les logs
- Utilisation sous forme de volumes est préférable
  - Sont stockés dans ***tmpfs*** et ne sont jamais écrits sur le disque
  - Sont mises à jour automatiquement
- Instanciables via un fichier YAML (*encodage base64*) ou directement avec ***kubectl***

credentials-secret.yaml

```
apiVersion: v1
kind: Secret
metadata:
  name: credentials
data:
  username: YWRtaW4=
  password: MWYyZDFlMmU2N2Rm
```

pod-with-secret.yaml

```
apiVersion: v1
kind: Pod
metadata:
  name: pod-with-secret
spec:
  containers:
  - name: nginx
    image: nginx
    volumeMounts:
    - name: credentials-vol
      mountPath: "/cred"
  volumes:
  - name: credentials-vol
    secret:
      secretName: credentials
```

ConfigMaps

- Permettent de stocker et de fournir aux conteneurs des données de configuration non confidentielles dans des paires clé-valeur
- Utiles pour définir les données de configuration séparément du code de l'application
- Peuvent être fournis à vos Prods sous forme
  - Variables d'environnement
  - Fichiers de configuration dans un volume
- Sont mises à jour automatiquement (si utilisés sous forme de volumes)

configmap-game-demo.yaml

```
apiVersion: v1
kind: ConfigMap
metadata:
  name: game-demo
data:
    game.properties: |
       enemy.types=aliens,monsters
       player.maximum-lives=5
```

Dans la partie spec du Pod

```
containers:
…
  volumeMounts:
  - name: config
    mountPath: "/config"
```

```
volumes:
  - name: config
    configMap:
      name: game-demo
      items:
        - key: "game.properties"
          path: "game.properties"
```

Configuration sera disponible dans /config/game.properties

Surveillance des applications

- K8s peut surveiller non seulement l'exécution des Pods mais aussi le fonctionnement des applications avec les mécanismes de
  - **Réparation des applications** via le redémarrage ou la recréation des conteneurs
  - **Rétention du trafic entrant** jusqu'au démarrage complet de l’application
- Pour utiliser ces mécanismes, vous devez **ajouter des sondes (probes) dans vos Pods**

Types de sondes

- **Sonde Liveness** — permet de vérifier si l’application exécutée dans un Pod fonctionne correctement
  - Si la vérification réussit, tout est en ordre
  - Si la vérification échoue, le conteneur est redémarré
- **Sonde Readiness** — permet de vérifier si l’application est capable de recevoir les demandes des clients
  - Si la vérification échoue, le conteneur n'est pas redémarré, mais le trafic n'est pas redirigé vers ce conteneur
- **Sonde Startup** — utile pour les applications avec un temps de démarrage long
  - Un moyen de différer l’exécution des sondes Liveness and Readiness
  - Attendre le temps de démarrage le plus défavorable et vérifier si l’application fonctionne

Mécanismes de vérification

- **HTTP Get probe**
  - Effectue une requête HTTP GET sur un port et un chemin
  - Vérification est considérée comme réussie si la réponse a un code d'état supérieur ou égal à 200 et inférieur à 400
- **TCP Socket probe**
  - Tente d'ouvrir une connexion TCP sur un port spécifique
  - Vérification est considérée comme réussie si le port est ouvert
- **Exec probe**
  - Exécute une commande arbitraire dans le conteneur
  - Vérification est considérée comme réussie si la commande se termine avec un *code* d'état de *0*
- **GRPC probe**
  - Effectue un appel de procédure à distance à l'aide de gRPC
  - Vérification est considérée comme réussie si le *state* de la réponse est *SERVING*

Dans la partie spec du Pod

```
containers:
…
  livenessProbe:
    httpGet:
      path: /
      port: 80
    periodSeconds: 5
```

```
containers:
…
  livenessProbe:
    tcpSocket:
      port: 8080
    periodSeconds: 5
```

```
containers:
…
  livenessProbe:
    exec:
      command: ["ping"]
    periodSeconds: 5
```

Cloud Controller Manager

- Composant de ***Control Plane*** qui permet de **lier un cluster K8s à l'API d'un fournisseur cloud**
  - Openstack, AWS (Amazon Web Services), GCP (Google Cloud Platform), Azure...
- Permet d'intégrer les fonctionnalités et des services du cloud provider dans un cluster K8s
  - Gestion automatisée des nœuds
  - Création et gestion des volumes
  - Création et configuration des load balancers
  - Utilisation de l'adressage IP et du network filtering
  - Délégation de l'authentification

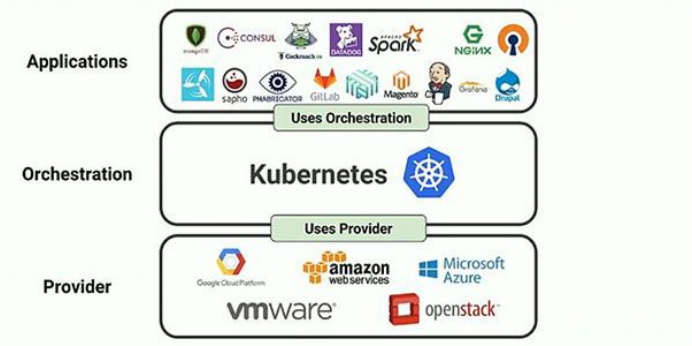

Source : https://www.fairbanks.nl/

Déployer un cluster Kubernetes

- **Kubeadm**
  - Outil **officiel** pour créer et gérer des clusters Kubernetes
- **kOps**
  - Outil de déploiement des clusters Kubernetes sur AWS et GCE
- **Kubespray**
  - Outil d'automatisation du déploiement des clusters Kubernetes avec **Ansible**
    - Sur GCE, Azure, OpenStack, AWS, vSphere, Equinix Metal, Oracle Cloud Infrastructure ou Baremetal
- **RKE** (Rancher Kubernetes Engine)
  - Outil qui facilite et automatise le déploiement, les mises à jour et les Rollbacks des clusters Kubernetes
- **Cluster API**
  - Sous-projet Kubernetes fournissant des outils pour simplifier le déploiement des clusters K8s
- Pendant les TPs, vous utiliserez le **RKE** et **Kubeadm** dans la partie bonus

Rancher Kubernetes Engine (RKE)

Déployer un cluster Kubernetes en 5 étapes

1. Téléchargez le binaire RKE et rendez-le exécutable
2. Installez Docker sur vos machines
3. Créez un fichier de configuration avec “rke config”
4. Lancez le déploiement du cluster avec “rke up”
5. Le cluster est fonctionnel

```
ubuntu@test-master:~/.kube$ kubectl get nodes
NAME              STATUS   ROLES               AGE     VERSION
192.168.166.150   Ready    controlplane,etcd   3m41s   v1.21.6
192.168.166.177   Ready    worker              3m36s   v1.21.6
192.168.166.200   Ready    worker              3m36s   v1.21.6
```

cluster.yml

```
nodes:
- address: 192.168.166.150
  port: "22"
  role:
  - controlplane
  - etcd
  user: ubuntu
- address: 192.168.166.200
  port: "22"
  role:
  - worker
  user: ubuntu
- address: 192.168.166.177
  port: "22"
  role:
  - worker
  user: ubuntu
```

Helm - Kubernetes application manager

- Gestionnaire de paquets pour Kubernetes
- Propose un marketplace (~18000 packages)
  - https://artifacthub.io
- Automatise le déploiement des objets Kubernetes

- **Exemple :** Déployer une solution de centralisation des logs Grafana Loki (Loki, Grafana, FluentBit)

```
helm upgrade --install loki grafana/loki-stack  \
      --set fluent-bit.enabled=true,promtail.enabled=false,grafana.enabled=true
```

Merci pour votre attention !